

# 南京工业大学硕士研究生中期考核表

学院	电气工程与控制科学学院		学科（二级）或专业 学位领域（专硕）	控制工程	
姓名	吴宇桁	学号	202361206115	性别	男
导师	史建涛、陈闯	研究方向	预测与健康管理		
培养计划应修学分		24	培养计划已修学分		24
个人中期总结（包含思想政治表现、学习情况、科研工作基本情况、获奖等。也可根据学院具体要求另附其它相关材料）					
<p>一、思想政治表现：</p> <p>本人时时刻刻要求自己在思想上保持与时俱进，在对党的重要思想和纲领的学习中，努力克服自己思想上的惰性，不断提高自己的思想政治觉悟，努力向优秀党员学习，虚心接纳别人的宝贵意见和建议，取他人之长补己之短，脱离了以前把学习当成任务的稚嫩思想，转而以更成熟的状态来体验研究生活。</p>					
<p>二、学习情况：</p> <p>在课程学习上，本人一直严格要求自己，努力学习专业知识，课程成绩良好。对于专业知识的学习，不是简单地去学习书本上和课堂上的知识，更多的是结合自己研究的方向，拓展相关领域的知识，发展前景等。</p>					
<p>三、科研基本情况：</p> <p>在科研方面，本人坚持阅读优秀文献，不断学习进步。在课题研究中，认真思考，主动与导师商量具体进展，学习与研究方向相关的前沿知识，积极地投入课题研究中去。目前，已取得的科研进展包括：发表 SCI 论文 2 篇（SCI 二区 1 篇，SCI 四区 1 篇），EI 会议论文 2 篇，授权发明专利 3 件，公开 1 件。</p>					
<p>四、获奖情况：</p> <p>本人荣获 2023 年研究生新生二等奖学金，2024 年研究生学业三等奖学金，2023-2024 学年第一学期“先进宿舍”称号，2023-2024 学年第二学期“先进宿舍”称号，2023 南京工业大学“图书馆优秀志愿者”，2024 “研究生党员示范宿舍”，2024 全国大学生英语竞赛 A 类全国三等奖，南京工业大学 2024 “e 动工大” 信息检索大赛一等奖。</p>					

注：1、请附硕士阶段成绩单；

2、各学位点可根据本单位考核要求增加考核内容，并相应调整考核表。

开题报告题目	基于改进 Transformer 的锂离子电池健康状态预测研究
一、研究内容简介：	
<p>随着电动汽车、可再生能源和便携式电子设备的广泛应用，锂离子电池的健康管理在现代技术和工业中扮演着至关重要的角色。电池健康状态（State-of-Health, SOH）的准确预测对于延长电池寿命、确保系统安全性和优化资源使用具有重要意义。因此，如何通过先进的数据驱动方法技术实现锂离子电池 SOH 的精准预测，成为了学术界和工业界关注的热点问题。目前，锂离子电池 SOH 预测研究主要集中在点预测和区间预测两个方面。点预测方法常用的包括直接测量法、模型法、数据驱动法以及混合法。直接测量法通过监测电池的物理参数，如内阻和电压等，直接预测 SOH，但其精度受限于测量设备的性能。模型法如等效电路模型和电化学模型，能够较为精确地反映电池内部特性，但依赖于复杂的物理模型和参数调优。数据驱动法利用机器学习和深度学习算法，通过历史数据训练模型以进行 SOH 预测，虽然具有较高的预测精度和适应性，但对数据质量要求较高且缺乏透明性。混合法则结合了物理模型和数据驱动法的优势，力求在准确性和适应性之间取得平衡。</p>	
<p>区间预测则通过提供预测值的置信区间，量化 SOH 预测中的不确定性，在应对复杂工况和动态变化时发挥了关键作用。常用的区间预测方法包括贝叶斯神经网络（Bayesian Neural Network, BNN）、蒙特卡洛 Dropout（MC Dropout）和模糊信息粒化等，尽管能有效处理非线性和高噪声数据，但在计算复杂度和实时性方面存在挑战。上述点预测和区间预测方法在锂离子电池 SOH 预测中依然面临着多尺度特征提取与融合困难、模型复杂度高、实时性不足等问题。</p>	
<p>对于点预测，本课题通过改进特征提取和特征选择方法，开发能够在多变量、不同工况环境中保持高精度的 SOH 预测模型。研究将探索多种数据驱动深度学习技术（如 Transformer、卷积神经网络（CNN, Convolutional Neural Network）、长短记忆网络（LSTM, Long Short-Term Memory））的集成应用，以提升健康状态预测的准确性。此外，通过将 Transformer 模型与其他智能诊断方法（如 CNN 基准模型、Unet 模块）相结合，开发具有更高鲁棒性和效率的 Transformer 模型，增强模型对电池老化过程和健康状态变化的敏感性，确保在不同使用条件下提供及时、准确的健康状态信息。</p>	
<p>对于区间预测，本课题将开发基于分位数回归（QR, Quantile Regression）和核密度估计</p>	

(KDE, Kernel Density Estimation) 的区间预测模型，并将其融入到 Transformer 结构中进行不确定性量化。通过将分位数回归层嵌入到 Transformer 改进网络的构建中，以获得不同分位数的容量。其次，利用核密度估计推导出每个电池循环阶段预测点的概率密度，实现对模型预测结果的不确定性评估。该方法将为每个预测结果提供置信区间，以量化和表达模型预测中的不确定性，从而提高决策的可靠性。研究将重点解决在多工况下区间预测的稳定性与精确性问题，为电池管理系统提供更全面的支持。整体技术路线如图 1 所示。

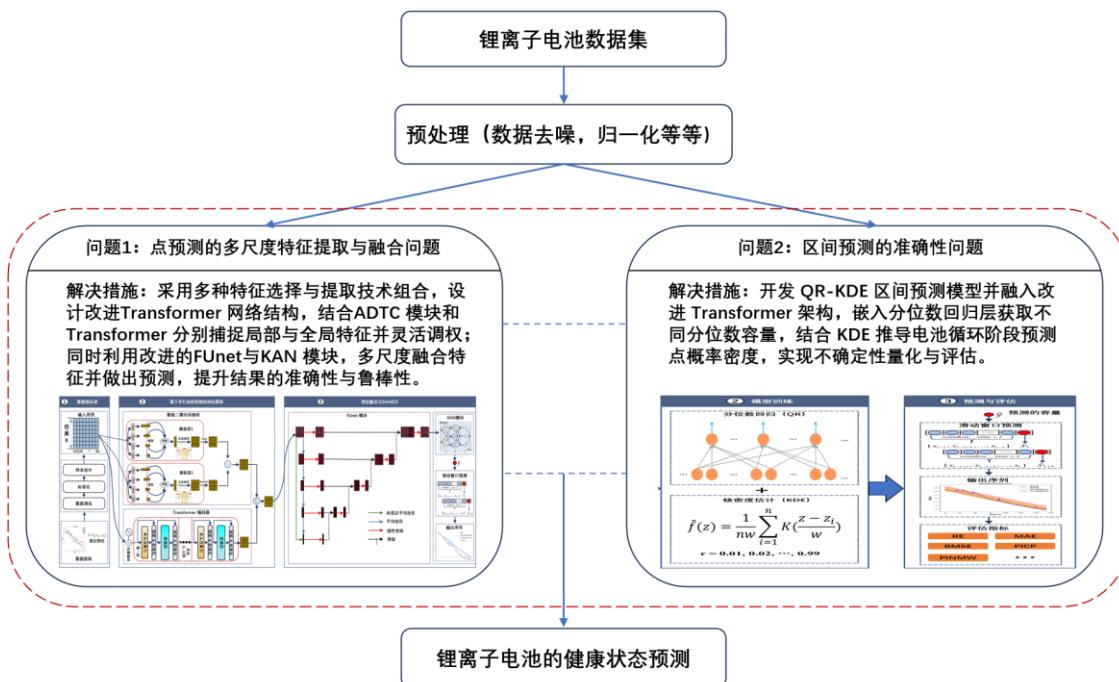


图 1 技术路线图

## 二、研究工作进展（详细叙述已经完成的主要工作内容）

目前的工作进度已完成了以下内容：

### I. 基于改进 Transformer 的锂离子电池 SOH 点预测模型

在实际工业生产中，锂离子电池的健康状态预测面临着许多挑战。为解决传统深度学习模型在多尺度特征融合、全局-局部特征平衡等方面的不足，本课题提出了一种新颖的混合模型，该模型的设计充分结合了多种现有模型的优势，并提出以下改进：通过自适应膨胀时间卷积（ADTC）模块，高效捕捉长序列依赖关系，兼具局部特征提取和全局特征识别能力；引入并行加权架构，通过平衡 ADTC 与 Transformer 的特征贡献，优化局部和全局特征的表示；进一步结合增强型 U-Net (FUNet) 模块，通过特征金字塔网络 (FPN) 提升多尺度特征

的融合效率，降低计算复杂度；最后通过 Kolmogorov-Arnold 网络（KAN）建模高维特征的复杂关系并做出预测，从而显著提升了预测的精度和鲁棒性，模型框架如图 2 所示。

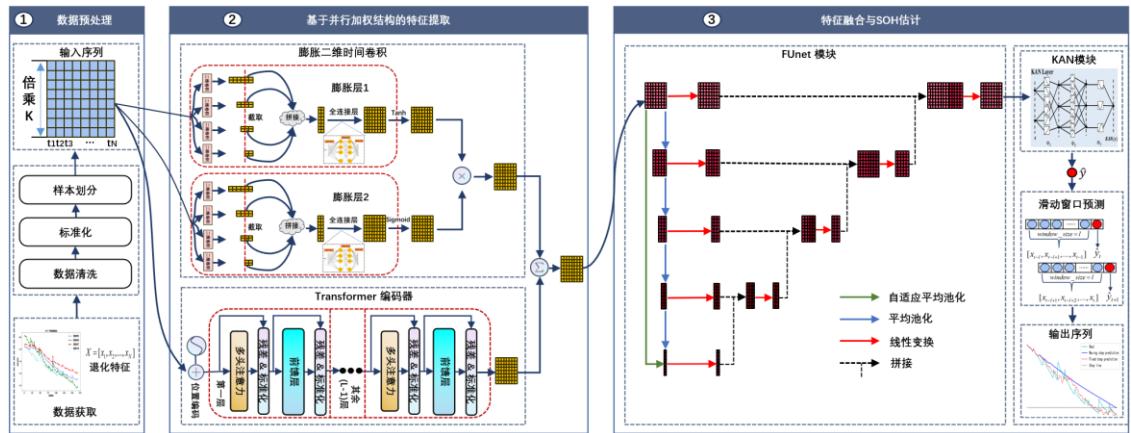


图 2 带有 FUNet 融合和 KAN 的并行加权 ADTC-Transformer 框架示意图

图 2 表明所提出的基于改进 Transformer 的锂离子电池 SOH 点预测模型核心在于 ADTC、Transformer、FUNet 和 KAN 四个模块。下面将详细介绍这四个模块。

#### A. ADTC 模块

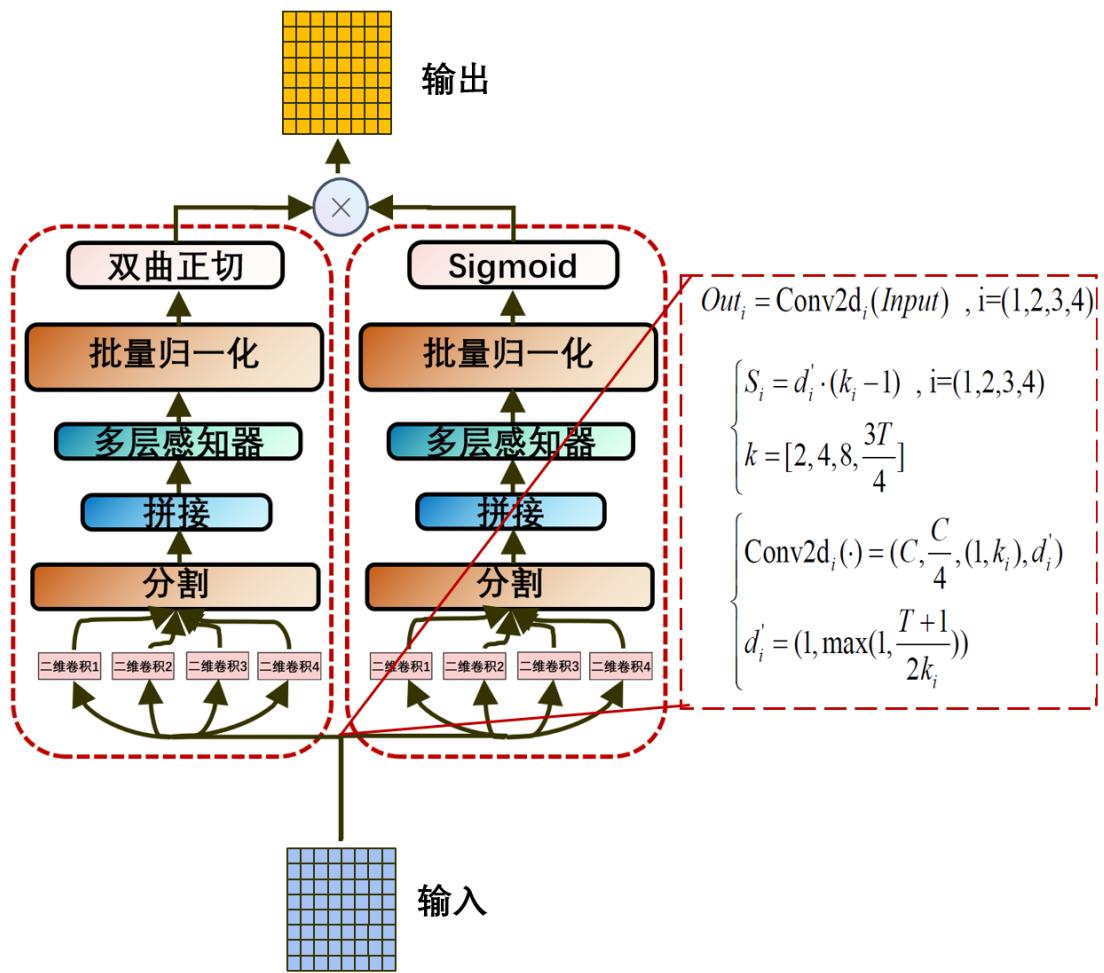


图 3 自适应膨胀时间卷积 (ADTC) 模块结构图

传统的时间序列卷积网络 (Temporal Convolutional Network, TCN) 因其高效的计算能力在时间序列建模中表现出色，其核心机制依赖于因果卷积 (Causal Convolution) 和膨胀卷积 (Dilated Convolution)，以实现时间依赖特征的捕捉。然而，随着实际应用场景的复杂化，传统 TCN 逐渐暴露出一些局限性。其卷积操作采用固定策略，例如指数增长的膨胀因子 (1, 2, 4, 8) 和固定卷积核大小 (2, 3)，这导致模型在处理多样化的时间特征时缺乏灵活性。具体而言，短期依赖特征可能被忽略，而过大的感受野又使长期依赖特征的关注力分散。此外，TCN 无法根据输入序列的特性动态调整结构，显著限制了其对不同时间序列数据的泛化能力。

针对这些不足，本文提出了一种自适应膨胀时间卷积模块 (ADTC)，模块结构如图 3 所示。该模块通过整合多分支结构、自适应膨胀策略和非线性激活机制，不仅能够细致地提取局部特征，还能灵活地建模全局依赖，显著提升特征表达能力。

ADTC 的设计核心是基于膨胀 Inception 结构的多分支卷积。在此结构中，不同的分支采用不同大小的卷积核（如 2, 4, 8 以及输入时间维度的  $3/4$  倍取整），并配以动态调整的膨胀因子。这种多分支设计在时间特征建模中表现出色：小卷积核分支能够捕捉局部时间步之间的细节特征，增强短期依赖的表达能力；而大卷积核分支则通过动态膨胀因子扩展感受野，有效捕捉长期依赖特征，从而建模全局趋势。膨胀因子的动态调整使模块能够根据输入序列长度灵活适应不同时间范围的特征建模需求。

多分支设计可能因卷积操作的不同而导致时间维度的不一致。为此，ADTC 采用动态时间对齐策略，通过截取最小时间长度来保证所有分支特征的一致性。对齐后的特征在通道维度上进行拼接，并通过两层全连接网络进一步优化特征的表达能力，从而确保多分支特征的有效融合。

为提升特征筛选和表达能力，ADTC 在模块末尾引入了非线性激活机制。这一机制由双膨胀卷积结构组成：一个膨胀卷积层后接双曲正切激活函数 ( $\tanh$ )，作为过滤器，用于提取关键特征；另一个膨胀卷积层后接 S 型激活函数 ( $\text{sigmoid}$ )，作为门控机制，用于动态控制过滤器传递的信息量。最终的模块输出通过过滤器和门控机制逐元素相乘生成，实现了特征的动态筛选与信息流的高效传递。这种激活机制结合了  $\tanh$  和  $\text{sigmoid}$  的优点，在复杂时间

依赖的建模任务中表现出极高的灵活性和鲁棒性。

## B. Transformer 模块

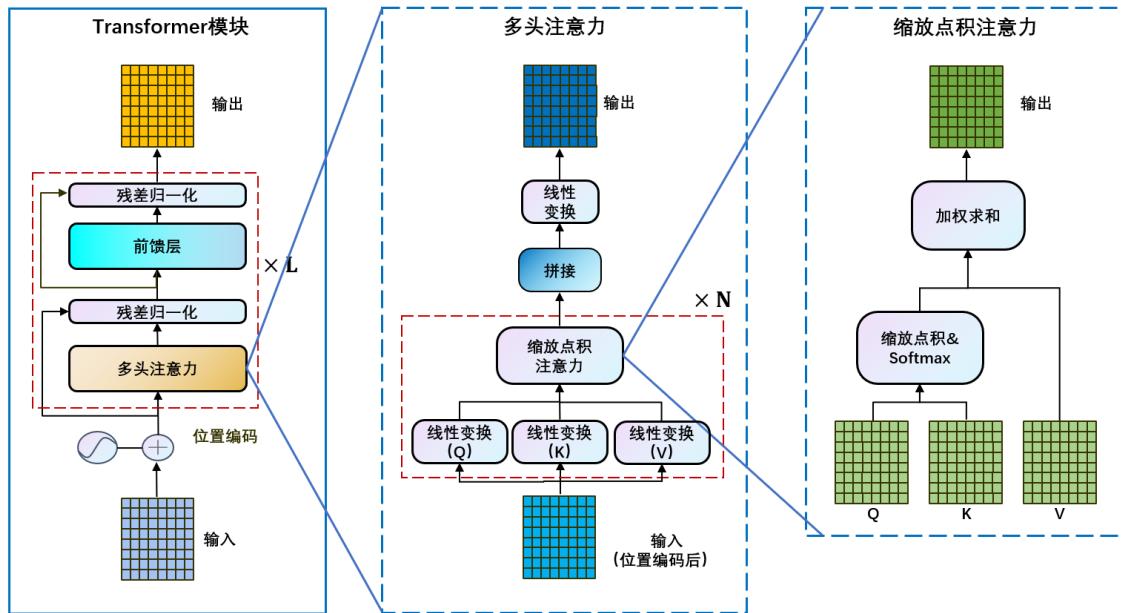


图 4 Transformer 编码器模块结构图

Transformer 作为一种以自注意力机制为核心的结构，近年来在序列建模任务中得到了广泛应用。其核心优势在于能够捕获时间序列中的全局依赖关系，并通过并行计算显著提升计算效率。本文采用了 Transformer 的编码器（Encoder）部分，通过堆叠多个编码器模块，结构如图 4 所示，实现对全局时间依赖特征的高效提取。编码器由多头注意力模块、Add & Norm 模块以及前馈网络模块组成，其设计逻辑和功能如下。

多头注意力模块通过结合位置编码与自注意力机制，有效挖掘输入序列特征之间的全局关系。首先，序列的位置信息通过正弦和余弦函数进行编码：

$$\begin{cases} PE(pos, 2u) = \sin(pos / 10000^{2u/h}) \\ PE(pos, 2u+1) = \cos(pos / 10000^{2u/h}) \end{cases} \quad (1)$$

其中， $pos$  是输入序列中对象的位置， $u$  是在所属向量中的位置， $h$  表示 Transformer 模型输出嵌入空间的维度。

将位置信息添加到原始输入  $x^{(i)}$  上，构成 Transformer 模型的多头注意力初始输入：

$$H^0 = x^{(i)} + PE^{(i)} \quad (2)$$

其中， $x^{(i)}$  指第  $i$  个特征样本作为输入， $PE^{(i)}$  指输入  $x^{(i)}$  对应的位置编码。

接着，输入特征通过多头注意力机制计算子特征之间的相关性，得到每个子头注意力的输出：

$$\begin{cases} PE(pos, 2u) = \sin(pos / 10000^{2u/h}) \\ PE(pos, 2u+1) = \cos(pos / 10000^{2u/h}) \end{cases} \quad (3)$$

其中， $Attention(\cdot)$ 指子头注意力的映射函数， $H^{l-1}$ 指第 $l-1$ 层编码器的输出， $Q_i$ ,  $K_i$ ,  $V_i$ 是Transformer模型中对于第 $l$ 层第 $i$ 个注意力子头的三个随机初始化的权重矩阵， $L$ 为Transformer模型中编码器堆叠的层数。

然后，对各子头的输出进行拼接并线性变换，形成多头注意力模块的输出：

$$MultiHead(H^{l-1}) = [head_1; head_2; \dots; head_n]W^O \quad (4)$$

其中， $MultiHead(\cdot)$ 为多头注意力的映射函数， $W^O$ 为多头注意力的权重矩阵。

多头注意力模块的输出通过Add & Norm层进行优化，以确保梯度稳定性并保留输入特征。具体操作包括将多头注意力的输出与原始输入相加，并进行层归一化操作：

$$H'^l = \text{LayerNorm}(MultiHead(H^{l-1}) + H^{l-1}) \quad (5)$$

其中， $MultiHead(H^{l-1})$ 为多头注意力部分的输出， $H^{l-1}$ 为原始输入即上一层编码器的输出， $\text{LayerNorm}(\cdot)$ 为层归一化操作。

在前馈网络部分，编码器采用两层线性变换网络，用于增强非线性建模能力。前馈网络的输出可表示为：

$$FFN(H'^l) = \text{ReLU}(H'^l W_1 + b_1) W_2 + b_2 \quad (6)$$

其中， $FFN(\cdot)$ 为前馈层的映射函数， $\text{ReLU}(\cdot)$ 为前馈层内置的激活函数的映射函数， $W_1$ 和 $W_2$ 为线性层的权重矩阵， $b_1$ 和 $b_2$ 为线性层的偏置项。

然后，再次通过Add & Norm层优化前馈网络输出：

$$H''^l = \text{LayerNorm}(FFN(H'^l) + H'^l) \quad (7)$$

其中， $FFN(H'^l)$ 为前馈层的输出， $H'^l$ 为多头注意力层的输出， $\text{LayerNorm}(\cdot)$ 为层归一化操作。

经过上述操作，Transformer的编码器模块通过层层堆叠的编码器单元逐步提取全局时间依赖特征。每一层编码器的输出都会传递至下一层进行更高层次的特征建模，直到最后一层，即第 $L$ 层编码器的输出完成对全局时间序列特征的整合优化：

$$H''^L = \text{LayerNorm}(\text{FFN}(H'^L) + H'^L) \quad (8)$$

通过这种层层递进的结构，Transformer 的编码器能够在全局建模与细节捕捉之间实现良好的平衡，为后续模块提供丰富且精准的特征表达。

### C. FUNet 模块

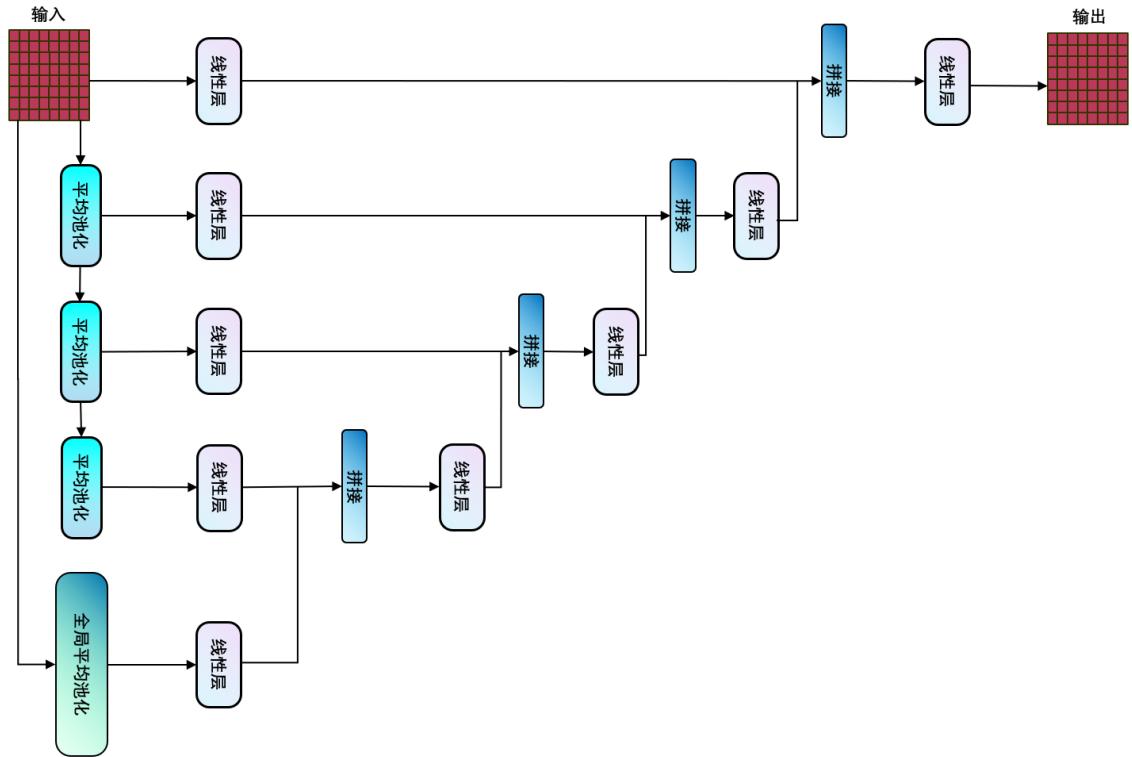


图 5 FUNet 模块结构图

传统 U-Net 架构以其编码-解码结构和跳跃连接的特点，在结合上下文信息与细节特征方面具有明显优势。然而，在特定任务，尤其是长时间序列数据建模中，其表现受到以下限制：首先，U-Net 通过局部卷积和池化操作完成特征提取，这使其在捕获全局特征时显得不足，特别是在处理复杂长序列依赖时。其次，其特征融合策略依赖于解码路径中的对应层级跳跃连接，这种方式无法充分结合深层次的全局趋势与浅层局部特征。最后，下采样过程中的池化操作尽管有助于压缩特征图，但也容易导致关键细节信息的丢失。

为克服这些局限性，本文设计了 FUNet 模块，结构如图 5 所示，并在以下几方面对传统 U-Net 进行了优化。首先，通过在最低层引入全局平均池化，FUNet 能够有效捕获高维数据的整体趋势特征，这些全局特征通过跳跃连接传递到解码路径中参与特征重建过程，从而显著增强了对长程依赖的建模能力。其次，结合特征金字塔网络（FPN）的方法，FUNet 通过平均

池化逐层提取浅层、深层和全局特征，在上采样路径中对这些多尺度特征进行了拼接和线性变换的融合操作。这种多层次特征交互的设计平衡了不同尺度的信息，使得模型能够更高效地处理各种长度和分辨率的时间序列数据，同时显著提升特征图融合的效率。

此外，为了进一步降低计算复杂度，FUnet 在设计中引入轻量化线性模块，分解部分卷积操作以适应长时间序列数据的处理需求。这种轻量化策略不仅提升了计算效率，还确保了对关键特征的有效捕获。

基于这些改进，FUnet 被置于 ADTC 和 Transformer Encoder 的并行加权模块后端。通过对局部与全局特征的加权融合特征图进行进一步的提炼与整合，FUnet 成功弥补了传统 U-Net 的不足，为时间序列建模提供了更全面和高效的解决方案。

#### D. KAN 模块

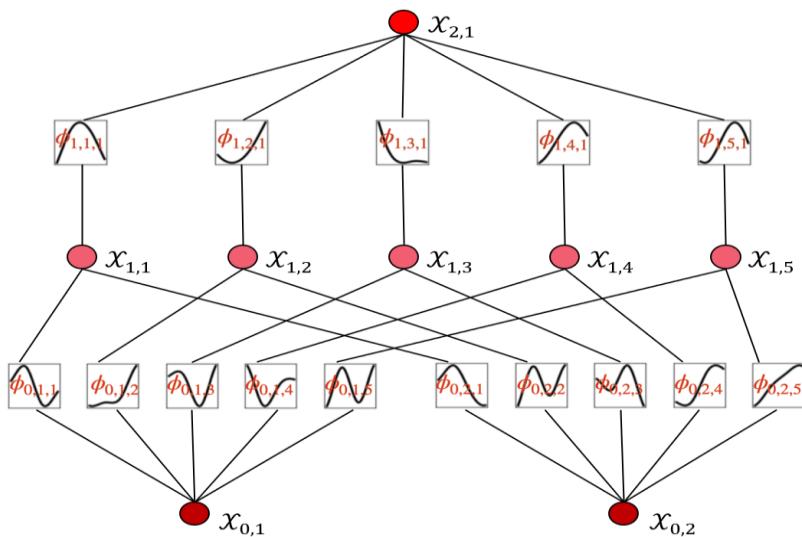


图 6 KAN 模块结构图

KAN (Kolmogorov-Arnold Network) 基于 Kolmogorov-Arnold 表示定理设计[31]，能够将任何连续的多维函数表示为若干单变量函数的嵌套组合，从而为复杂高维数据的处理提供理论支撑。在锂离子电池预测任务中，高维数据间常存在复杂非线性关系，KAN 通过其特有的非线性激活和线性组合特性，可有效降低高维数据的复杂性，实现特征的高效建模与利用。因此，KAN 模块在整个架构中被置于 FUnet 模块之后，作为最终预测模块，其结构如图 6 所示。

KAN 的总体公式如下：

$$KAN(x) = f(x_1, x_2, \dots, x_n) = \sum_{q=1}^{2n+1} \Phi_q \left( \sum_{p=1}^n \varphi_{q,p}(x_p) \right) \quad (9)$$

具体而言，首先，KAN 通过输入特征  $x_p$  的分布动态生成网格节点位置，基于 b 样条基函数对每个输入特征通过网格节点实现插值，所有插值结果被线性组合以生成聚合结果  $\varphi_{q,p}(x_p)$ ，公式如下：

$$B_{i,k}(x_p) = \frac{x_p - t_i}{t_{i+k} - t_i} B_{i,k-1}(x_p) + \frac{t_{i+k+1} - x_p}{t_{i+k+1} - t_{i+1}} B_{i+1,k-1}(x_p) \quad (10)$$

$$\varphi_{q,p}(x_p) = \sum_{i=1}^N w_i B_{i,k}(x_p) \quad (11)$$

其中， $t_i$  为插值节点的位置， $k$  为 b 样条的度数， $w_i$  为可学习权值， $N$  为插值节点数。

之后，对样条结果进行加权求和，得到所有输入特征  $x_p$  的局部插值结果  $\sum_{p=1}^n \varphi_{q,p}(x_p)$ ，结合非线性激活函数和偏置项，利用  $\Phi_q$  对进行全局非线性处理。公式如下：

$$\Phi_q(y_q) = \sigma \left( \sum_{j=1}^m v_{q,j} \cdot y_{q,j} + b_q \right) \quad (12)$$

其中， $\Phi_q$  为 KAN 模型中的全局非线性变换因子， $y_q$  表示插值后所有输入特征的局部插值结果之和， $\sigma(\cdot)$  为非线性激活函数， $v_{q,j}$  为全局非线性变换层的可学习权值， $b_q$  为偏置项，表示偏移量， $m$  为全局函数层的节点数。

KAN 通过可学习的样条权值和激活函数参数，使其能够动态适配不同输入数据分布，实现了对并行加权结构与 FUnet 处理后的复杂高维特征的有效建模，确保最后的 SOH 预测结果具有更高的准确性与鲁棒性。

#### E. 实验验证

1) 为了验证所提模型的有效性，本文选用了 NASA、CALCE 和 WRBD 三大数据集，这些数据集提供了在不同实验条件下的电池退化信息。

(1) NASA 数据集包括 18650 锂离子电池 (B0005、B0006、B0007、B0018) 的测试数据。这些测试在 24°C 的室温条件下进行，采用恒流 (CC) 模式以 1.5 A 电流充电至 4.2 V，随后切换至恒压 (CV) 充电，直到电流降至 20 mA。放电过程在恒流 2 A 下进行，截止电压分别为 2.7 V、2.5 V、2.2 V 和 2.5 V。电池寿命终止 (EOL) 标准为电池容量衰减至初始额定容量的 30%，即从 2 Ah 降至约 1.4 Ah。该数据集详细记录了不同工况下的退化趋势，是电池

SOH 预测领域中常用的基准数据集。电池容量如图 7 (a) 所示，实验装置如图 8 (a) 所示。

(2) CALCE 数据集由先进生命周期工程中心 (CALCE) 提供，包含四个电池 (CS2\_35、CS2\_36、CS2\_37、CS2\_38) 的数据。测试在 1°C 的控制温度下进行，充电采用恒流模式至 4.2 V 后切换至恒压充电，直至电流降至 20 mA。放电以恒流模式进行，截止电压为 2.7 V。EOL 标准同样定义为额定容量下降 30%，即从 1.1 Ah 降至约 0.77 Ah。该数据集捕捉了在严格实验室条件下的退化特性，为 SOH 预测建模提供了宝贵的数据支持。电池容量如图 7 (b) 所示，实验装置如图 8 (b) 所示。

(3) 温州随机电池数据集 (WRBD) 由本实验室采集与处理，用以补充 NASA 和 CALCE 的公共数据集。WRBD 数据集包含四个锂离子电池 (A\_001、A\_003、A\_004、A\_006) 的数据，这些电池均在标准的恒流/恒压协议下测试。充电过程以 1C 电流充至 4.2 V 后切换至恒压模式，直到电流降至 0.05C。放电过程以 1C 电流至截止电压 2.75 V 完成。测试均在室温条件下进行，并定期记录容量衰减情况。EOL 标准为容量从 1.0 Ah 降至约 0.7 Ah。WRBD 数据集提供了独特的、高质量的退化数据，增加了训练和评估过程的多样性与鲁棒性。电池容量如图 7 (c) 所示，实验装置如图 8 (c) 所示。

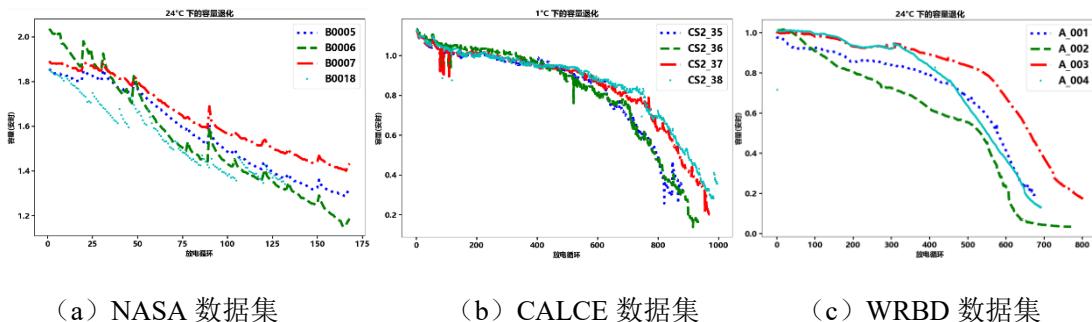
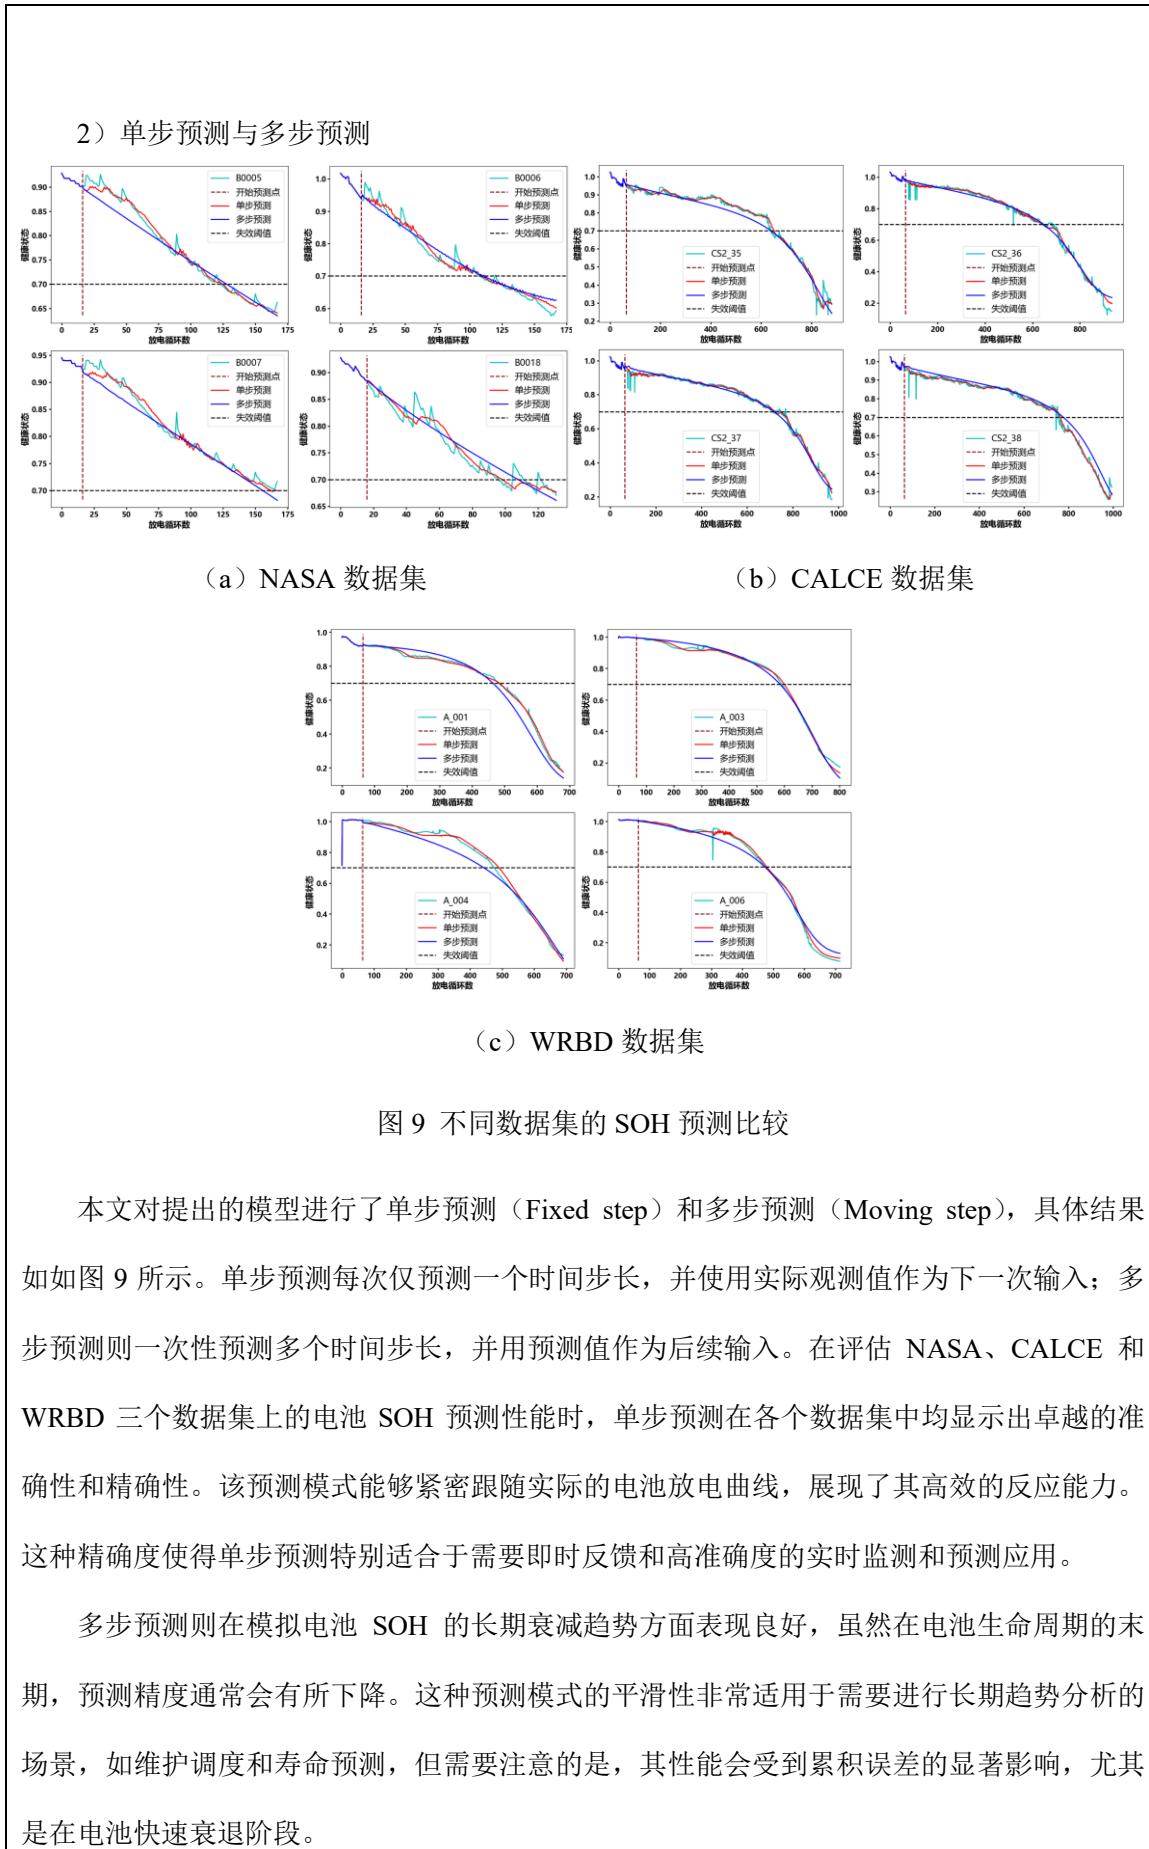


图 7 不同数据集的电池容量



图 8 不同数据集的实验装置



就数据集的具体特性而言，NASA 数据集中的电池展示了相对稳定的衰减过程，预测结果显示出良好的贴合度和低误差率，体现了模型的可靠性。CALCE 数据集的电池在控制严格的实验条件下展现出不同的衰减模式，模型在这些条件下展现了出色的适应性和准确性，尤其是在处理电池容量的快速变化方面表现突出。而 WRBD 数据集提供了更为复杂的现实世界电池使用场景，电池的衰减行为表现得更为多变和不规则。尽管面临更大的挑战，模型仍能够较好地捕捉到长期趋势，展现了其广泛的应用潜力和良好的适应性。

### 3) 消融实验

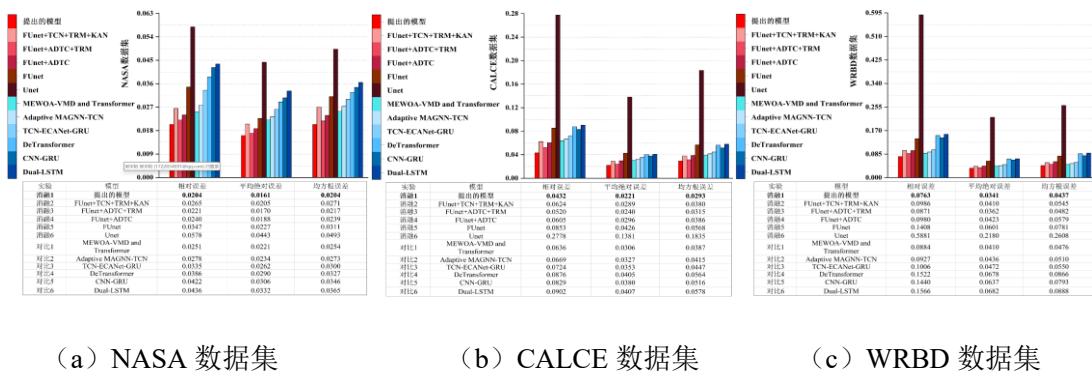


图 10 不同数据集的评估指标比较

本文通过逐步增加各个模块对电池状态健康 (SOH) 预测模型进行了详细的消融实验，具体如图 10 所示。基础的 U-Net 模型作为性能基线，展示了在捕捉电池基本特征方面的基础能力，但面对复杂的电池衰减模式时表现有限。随后引入的 FUNet，通过整合特征金字塔网络 (FPN)，显著增强了对多尺度信息的处理能力，优化了对电池容量变化各阶段的捕捉。结合自适应膨胀时间卷积 (ADTC) 的 FUNet 进一步强化了时间序列数据的处理能力，特别是在识别电池性能中的长期依赖关系上。通过加入 Transformer 模块，FUNet+ADTC 配置得以精准捕捉全局依赖关系，从而提升了预测的准确性和稳定性。最终，加入 Kolmogorov-Arnold 网络 (KAN) 的完整模型在处理高维特征和复杂函数映射方面显示出卓越性能，显著降低了各项误差指标，如相对误差 (RE)、平均绝对误差 (MAE) 和均方根误差 (RMSE)，彰显了该复合模型在挑战性电池衰减数据处理任务中的优越性。整体而言，每个新增模块的加入不仅证实了其有效性，还增强了模型在电池健康监测中的实用性和可靠性。

### 4) 对比试验

本文进行了一系列对比实验，旨在评估新提出的完整模型 (FUNet+ADTC+TRM+KAN)

与包括 Dual-LSTM、DeTransformer、CNN-GRU、TCN-ECANet-GRU 及 MEWOA-VMD and Transformer 在内的其他先进模型在锂离子电池 SOH 预测上的性能。简单组合模型虽在特定条件下可提供可靠预测，但在处理高维复杂数据时常显不足；而复杂组合模型则凭借其先进的数据处理能力，在预测精度和稳定性方面通常表现更佳，尤其擅长应对类似 WRBD 数据集这种噪声和变化都很大的复杂数据环境。本文提出的 FUNet+ADTC+TRM+KAN 模型在所有对比实验中表现最为出色，特别是在高难度数据集上，通过整合特征金字塔网络、自适应膨胀时间卷积、Transformer 及 Kolmogorov-Arnold 网络，该模型显著提升了特征提取效率和准确性，并优化了长期依赖关系的捕捉和处理。实验结果显示，该模型在 RE、MAE、RMSE 等关键性能指标上均优于其他模型，尤其在处理包含复杂衰退模式和噪声数据的电池数据集时表现尤为突出。这一系列对比实验不仅验证了新模型的设计正确性，也展示了其在实际应用中的潜力和价值，为未来电池健康管理系统的技术支持提供了坚实的基础。

##### 5) 权值调试实验

在权值调试实验中，本文将 ADTC 和 Transformer (TRM) 的权值之和设为 1，并分别测试了 ADTC 和 Transformer 权值在“0.1+0.9”、“0.2+0.8”……“0.9+0.1”的九种组合，旨在探讨局部特征与全局特征在不同权值分布下的贡献平衡。此外，为了验证这种权值调试的合理性，实验还将这些组合的结果与直接简单相加的权值分布（1:1 比值，即未加权处理）进行了对比分析。通过这种设置，研究不同数据集的特性对权值分布优化的影响，为模型设计提供数据支持。具体实验结果如表 1 所示。

权值调试实验的结果表明，不同数据集特性对模型中 ADTC 与 Transformer 权值的分布和性能影响存在显著差异。当 ADTC 与 Transformer 的权值相等时，模型表现较为理想，但未达到最佳。对于 NASA 数据集，该数据集以短序列为主（长度约 132~168），局部特征主导性能，最佳权值分布为 ADTC 占比 0.6，而全局特征的占比低不会显著影响表现。对于 CALCE 数据集，该数据集为长序列（长度约 881~995），局部与全局特征的平衡尤为重要，最佳权值分布为 ADTC 占比 0.7。对于 WRBD 数据集，该数据集的序列较长且复杂性高（长度约 681~801），局部特征的贡献更为重要，最佳权值分布为 ADTC 占比 0.8。

表 1 ADTC 与 Transformer 权值分布调试实验的结果比较

模型	数据集	权重分布		评价指标		
		ADTC	TRM	相对误差	平均绝对误差	均方根误差
提出的模 型	NASA	1	1	0.0204	0.0161	0.0204
		0.1	0.9	0.0245	0.0184	0.0212
		0.2	0.8	0.0204	0.0158	0.0203
		0.3	0.7	0.0208	0.0161	0.0201
		0.4	0.6	0.0202	0.0157	0.0193
		0.5	0.5	0.0203	0.0157	0.0192
		<b>0.6</b>	<b>0.4</b>	<b>0.0194</b>	<b>0.0150</b>	<b>0.0181</b>
		0.7	0.3	0.0213	0.0164	0.0195
		0.8	0.2	0.0195	0.0150	0.0186
		0.9	0.1	0.0237	0.0182	0.0212
	CALCE	1	1	0.0432	0.0221	0.0293
		0.1	0.9	0.1390	0.0692	0.0916
		0.2	0.8	0.0860	0.0456	0.0543
		0.3	0.7	0.0902	0.0412	0.0666
		0.4	0.6	0.1066	0.0585	0.0723
		0.5	0.5	0.0621	0.0355	0.0456
		0.6	0.4	0.0469	0.0255	0.0326
		<b>0.7</b>	<b>0.3</b>	<b>0.0386</b>	<b>0.0205</b>	<b>0.0279</b>
		0.8	0.2	0.0918	0.0692	0.0707
		0.9	0.1	0.0557	0.0315	0.0392
	WRBD	1	1	0.0763	0.0341	0.0437
		0.1	0.9	0.1428	0.0558	0.0770
		0.2	0.8	0.1073	0.0468	0.0671
		0.3	0.7	0.1148	0.0518	0.0617
		0.4	0.6	0.1299	0.0512	0.0671
		0.5	0.5	0.0785	0.0320	0.0434
		0.6	0.4	0.0535	0.0267	0.0343
		0.7	0.3	0.0680	0.0308	0.0387
		<b>0.8</b>	<b>0.2</b>	<b>0.0541</b>	<b>0.0245</b>	<b>0.0310</b>
		0.9	0.1	0.1066	0.0358	0.0498

从权值分布对性能起伏的影响来看，NASA 数据集表现出较小的性能波动。这是由于其短序列特性和单一的数据模式决定的，局部特征占据主导地位，ADTC 即可满足特征提取需求，权值调整对性能的影响有限。而对于 CALCE 和 WRBD 数据集，权值分布变化对性能的影响较为显著。CALCE 和 WRBD 数据集的长序列特性表明局部与全局特征的重要性需要精确平衡，权值失衡会导致性能显著下降。此外，WRBD 数据集因其更高的复杂性，对局部特征的依赖更强，权值分布不合理时表现出更大的性能波动。

数据集特性进一步揭示了短序列和长序列在权值分布上的差异。短序列中，局部特征占主导，权值变化的影响较小；而长序列则需要更好地平衡局部与全局特征，权值分布变化会引起显著的性能波动。同时，数据复杂性越高（如 WRBD 数据集），对局部特征的依赖增强，权值分布不合理会加剧性能的不稳定性。

实验表明，ADTC 在局部特征提取方面表现优异，凭借多分支结构、自适应膨胀卷积和非线性激活机制，能够精准建模短时间依赖特征，而其全局特征的捕获则通过多尺度感受野间接实现。相比之下，Transformer 凭借自注意力机制直接捕获全局依赖，擅长建模长期特征趋势，但在局部特征敏感性上略显不足。因此，优化权值分布需要结合序列长度和数据复杂度进行动态调整，例如 NASA 的最佳分布为 0.6:0.4，CALCE 为 0.7:0.3，WRBD 为 0.8:0.2。

综合来看，NASA 数据集的局部特征主导使得权值分布变化对性能影响较小，而 CALCE 和 WRBD 数据集因序列较长且复杂度更高，表现出更大的权值分布敏感性。未来研究将致力于探索动态权值分配和模块协同优化策略，以进一步提升模型的鲁棒性与适应性，为更广泛的数据场景提供可靠的解决方案。

## II. 基于改进 Transformer 的锂离子电池 SOH 区间预测模型

在点预测基础之上，通过将分位数回归层嵌入到 Transformer 改进网络的构建中，以获得不同分位数的容量。其次，利用核密度估计推导出每个电池循环阶段预测点的概率密度，实现对模型预测结果的不确定性评估。模型框架如图 11 所示。



四、取得的成果							
1、发表论文							
序号	题目	期刊名称 (全称)	论文作者、学生 排名、署名单位	SCI、EI 期刊、EI 会议、 ISTP、核 心	中科院分 区	发表情况 (“√”)	
						发表	录用
1	A Parallel Weighted ADTC-Transformer Framework with FUNet Fusion and KAN for Improved Lithium-ion Battery SOH Prediction	Control Engineering Practice	Chuang Chen, <b>Yuheng Wu,</b> Jiantao Shi, Dongdong Yue, Ge Shi, Dongzhen Lyu 导师第 1、 本人第 2 南京工业大学	SCI	2 区	√	4.6
2	Leveraging Trend-Aware Attention in Transformers for Lithium-Ion Battery Capacity Prediction	IEEE sensors letters	Chuang Chen, <b>Yuheng Wu,</b> Jiantao Shi, Dongdong Yue, Hongtian Chen 导师第 1、 本人第 2 南京工业大学	SCI	4 区	√	2.2

3	A Hybrid Framework for Lithium-Ion Battery Capacity Prediction Using TimesNet and Transformer	The 2025 Information Science Frontier Forum and the Academic Conference on Information Security and Intelligent Control (ISF)	<b>Yuheng Wu,</b> Chuang Chen, Jiantao Shi, Dongdong Yue, Cuimei Bo 本人第 1 南京工业大学	EI 会议	√		
4	A Novel Transformer Model with Trend-Aware Self-Attention for Accurate Lithium-Ion Battery Capacity Prediction	2025 Joint International Conference on Automation-Intelligence-Safety (ICAIS) & International Symposium on Autonomous Systems (ISAS)	<b>Yuheng Wu,</b> Chuang Chen, Jiantao Shi, Dongdong Yue, Cuimei Bo 本人第 1 南京工业大学	EI 会议	√		

## 2、申请专利

序号	专利名称	专利状态	学生排名	署名单位	专利号
1	一种基于伪标签引导 Transformer 学习的雷达收发器故障诊断方法	已授权	导师第 1、 本人第 2	南京工业大学	ZL202410932483

2	一种基于趋势感知注意力和 Transformer 编码器的锂离子电池健康状态估计方法	已授权	导师第 1、本人第 2	南京工业大学	ZL202411217269
3	一种基于 TCN-UnetTSF 模型的锂离子电池容量预测方法	已授权	导师第 1、本人第 2	南京工业大学	ZL202411217268
4	一种具有风险规避的航空发动机寿命预测和维护方法	已公开	导师第 1、本人第 2	南京工业大学	CN202410072172

### 3、科研奖励

序号	奖项名称	颁奖单位	获奖时间、获奖级别	学生排名、获奖单位

### 4、参加科研项目

序号	参加项目名称	项目来源	主要参加者、学生排名	本人在项目中承担的任务和完成情况
1	集成深度学习与多尺度方法的锂离子电池健康预测研究	江苏省教育厅	陈闯、史建涛、吴宇桁,本人第 1	实验设计、论文撰写, 在研
2	不确定性下的高端装备制造剩余寿命预测与维护决策优化	江苏省教育厅	陈闯、史建涛、李梦辰、周子豪、吴宇桁,本人第 3	数据处理, 结项

3	高端控制装备健康状态评估及故障智能预测预警技术研究	浙江大学工业控制技术全国重点实验室开放课题	陈闯、史建涛、李梦辰、周子豪、吴宇桁,本人第3	数据采集, 在研
4	铣刀状态管理及预测项目建设	南京米萨网络科技有限公司	陈闯、史建涛、李梦辰、周子豪、吴宇桁,本人第3	数据处理, 在研

## 5、其他科研实践和社会实践

在科研和社会实践方面,我积极参与了多种活动,以提升自己的学术能力和社会责任感。在学术交流方面,我参加了多场学术会议,通过与专家学者的深入讨论,拓宽了自己的研究视野,了解了最新的研究动态与技术前沿。尤其是在参加的 2025 年信息科学塞上前沿论坛暨信息安全与智能控制学术会议 (The 2025 Information Science Frontier Forum and the Academic Conference on Information Security and Intelligent Control) 和第二届“智能自动化与系统安全”暨第八届“自主无人系统”国际会议 (2025 Joint International Conference on Automation-Intelligence-Safety (ICAIS) & International Symposium on Autonomous Systems (ISAS)) 上,不仅向领域内的顶尖学者学习,还展示了自己的研究成果,得到了宝贵的反馈和建议。在实践能力的培养方面,我积极参与了研究生数学建模竞赛。在这个竞赛中,我不仅巩固了所学的数学知识,还锻炼了团队合作和问题解决的能力。通过对实际问题的建模与分析,让我体会到理论与实践相结合的重要性。

此外,我参与了导师国家自然科学基金青年科学基金项目的研究。这一项目为我提供了一个深入的研究平台,让我有机会参与前沿科学研究。在项目中,我负责数据分析和模型构建,培养了严谨的科研态度和扎实的实践技能,也锻炼了我的文献综述和科研论文撰写能力。我还参与了导师浙江大学工业控制技术全国重点实验室的开放课题,深入探索了工业控制领域的相关问题。在这一过程中,我与实验室的研究人员紧密合作,提升了自己的研究能力。同时,我也理解了如何将理论研究与实际应用相结合,为未来的研究打下了良好的基础。

通过以上这些科研实践和社会实践,我不仅提升了自己的专业技能,也增强了对社会的责任感。这些经历使我更加坚定了未来致力于将科研成果服务于社会发展的决心,也为我今后的科研之路奠定了坚实的基础。

## 6、专业实践情况（专业学位硕士生填写）

在南京新微海电子科技有限公司开展专业实践期间，聚焦无人机视觉检测在城市综合治理领域的应用，深度参与相关系统的开发与调试工作。

在视觉检测算法研究与应用层面，运用深度学习技术，如 Transformer、CNN 等计算机视觉算法，针对城市综合治理中的桥梁裂缝、城市垃圾、非法钓鱼等不同检测目标，开发对应的识别与检测模型。例如，针对桥梁裂缝检测，通过分析大量桥梁图像数据，提取裂缝的纹理、形状等特征，优化 CNN 网络结构，提升裂缝识别的准确率；对于城市垃圾和非法钓鱼场景，利用目标识别与检测算法，精准定位垃圾堆积区域和非法钓鱼行为发生位置。

数据处理与分析环节，承担大规模城市场景图像、视频数据的清理、标注与特征提取工作。借助 LabelImg 工具对无人机拍摄的海量城市图像进行目标检测标注，构建桥梁裂缝、城市垃圾、非法钓鱼等多类别的标注数据集，为后续模型训练提供高质量数据支撑，并从标注数据中挖掘有效特征，助力模型性能优化。

模型训练与优化方面，基于 TensorFlow、PyTorch 框架，对视觉检测模型进行训练与调优。不断调整网络参数、优化损失函数，提升模型在识别准确率、处理速度以及鲁棒性等方面的性能，随后将优化后的模型部署至无人机平台，并根据实际检测效果定期迭代升级，以适应不同天气、光照等城市环境下的检测需求。

此外，还参与文档与知识沉淀工作，编写数据标注流程、模型调优方案以及算法研究记录，形成标准化的操作与技术文档，帮助新成员快速上手相关工作，提升团队在无人机视觉检测用于城市综合治理方面的工作效率。

同时，协助无人机机巢、云台等硬件部件的调试与维护，进行机巢开关机检查、云台方向调节、基本状态确认等日常维护，保障无人机能正常起降，为视觉检测任务的稳定开展提供硬件支持，也让自己对机巢与视觉检测飞行任务的流程有了直观认识，为后续可能涉及的软硬件联调与接口开发工作奠定基础。

通过此次专业实践，在无人机视觉检测算法开发、数据处理、模型优化以及硬件协同等方面的能力得到显著提升，对深度学习驱动下的无人机视觉检测技术服务城市综合治理的应用场景与技术要点有了更深刻的理解。

指导教师评价意见

(就硕士生思想政治、学习能力、科研与实践能力、研究成果、综合素质等方面进行评价)

吴宇桁同学政治立场坚定，始终主动学习党的创新理论，紧跟理论前沿与政策导向，政治素养与思想觉悟突出，能以高标准要求自身思想言行，具备良好的政治判断力与政治领悟力，在学术研究中始终坚守正确价值导向，展现出成熟的思想认知与道德修养。

学业方面，该生勤奋严谨、成绩优异，不仅扎实掌握“控制工程”领域核心专业知识，还能结合“预测与健康管理”研究方向，主动拓展锂离子电池 SOH 预测相关的前沿技术与跨领域知识，学习规划清晰、执行力强，体现出高效的自主学习与知识整合能力。

科研能力尤为突出。该生深耕锂离子电池健康状态预测课题，熟练运用改进 Transformer 等技术，创新性提出 ADTC - Transformer 并行加权结构、FUnet 模块优化方案，解决多尺度特征融合、全局-局部特征平衡等关键问题；同时，积极跟进区间预测技术，对分位数回归等进行探索，开展第二个研究方向的相关工作。实验设计严谨，完成 NASA、CALCE、WRBD 多数据集验证，通过多类实验全面验证模型性能，数据处理与优化能力强。目前已发表 SCI 论文 2 篇（二区 1 篇、四区 1 篇）、EI 会议论文 2 篇，授权发明专利 3 件、公开 1 件，成果质量与数量居同期研究生前列，彰显扎实科研基础与创新潜力。

实践能力亮眼，该生参与企业无人机飞控系统开发，负责硬件测试、故障诊断等工作，实现理论与实践转化；还参与学术会议、数学建模竞赛及多项科研项目，承担实验设计、数据处理等核心任务，团队协作与问题解决能力显著。

综合素质全面，该生时间管理高效、责任心强，积极参与宿舍建设、图书馆志愿服务，获研究生新生二等奖学金、全国大学生英语竞赛 A 类全国三等奖等荣誉，展现谦逊务实、全面发展的良好风貌。

综上，吴宇桁同学在思想、学业、科研、实践等方面均表现优异，完全达到硕士研究生中期培养要求，后续可期持续产出高质量研究成果，为相关领域发展贡献力量。

指导教师（签名）：

年   月   日

考核小组意见	<table border="1"> <thead> <tr> <th>姓名</th> <th>职称</th> <th>所在单位</th> <th>备注</th> </tr> </thead> <tbody> <tr><td>董静</td><td>副教授/硕导</td><td>南京工业大学</td><td></td></tr> <tr><td>杨函煜</td><td>讲师/硕导</td><td>南京工业大学</td><td></td></tr> <tr><td>李昊天</td><td>讲师</td><td>南京工业大学</td><td></td></tr> <tr><td></td><td></td><td></td><td></td></tr> <tr><td></td><td></td><td></td><td></td></tr> </tbody> </table> <p>考核评价：</p> <p>考核小组对研究工作进行全面审查，认为其前期研究基础扎实：实验设计严谨，采用公共与自主采集的共三个数据集开展验证，通过单步/多步预测、消融实验、对比实验及权值调试实验等多维度验证模型性能，数据真实可信，结果分析合理。</p> <p>另外，考核小组就研究细节进一步评议：其一，关于模型呈现与数据规模，建议后续论文通过增加可视化图表（如特征提取过程示意图、不同权重下误差变化曲线）让内容更生动；其二，后续研究可进一步强化区间预测模型的实验验证，增加复杂工况下的测试场景，以更充分验证模型稳定性；</p> <p>综上，该生研究逻辑清晰、方法科学，对考核中涉及的技术细节均能合理回应，后续需按建议优化论文呈现与数据验证，持续推进区间预测模型深化研究。经考核小组评议，维持该生中期考核优秀结论，建议按计划开展后续工作。</p> <p style="text-align: center;"><input checked="" type="checkbox"/>优秀      <input type="checkbox"/>合格      <input type="checkbox"/>不合格</p> <p>考核小组成员（签名）：</p> <p style="text-align: right;">年    月    日</p>				姓名	职称	所在单位	备注	董静	副教授/硕导	南京工业大学		杨函煜	讲师/硕导	南京工业大学		李昊天	讲师	南京工业大学									
	姓名	职称	所在单位	备注																								
	董静	副教授/硕导	南京工业大学																									
	杨函煜	讲师/硕导	南京工业大学																									
	李昊天	讲师	南京工业大学																									
考核领导小组意见	<p>考核结论：</p> <p style="text-align: center;"><input checked="" type="checkbox"/>优秀      <input type="checkbox"/>合格      <input type="checkbox"/>不合格</p> <p>负责人（签名）： 学院（盖章）</p> <p style="text-align: right;">年    月    日</p>																											